

PRMLゼミ

1.2 確率論

anmitsu48

1.2節のイントロ

同時確率と周辺確率

- 1回の試行で確率変数 X, Y の両方についてサンプルをとる。この試行を N 回行ったとする。
- X が x_i , Y が y_j をとる確率: $p(X = x_i, Y = y_j)$


同時確率

- X が x_i , Y が y_j となる試行が n_{ij} 個あったとすると、

$$p(X = x_i, Y = y_j) = \frac{n_{ij}}{N}$$

- 周辺確率 (Y に関する周辺化)

$$p(X = x_i) = \sum_j p(X = x_i, Y = y_j)$$



同時確率と条件付き確率

- 変数 X が x_i の下で、変数 Y が y_j となる確率。
(条件付き確率)

$$p(Y = y_j | X = x_i) = \frac{p(X = x_i, Y = y_j)}{\sum_j p(X = x_i, Y = y_j)}$$

分母は X が x_i となる確率

- 条件付き確率の公式



$$p(X, Y) = p(Y|X)p(X) = p(X|Y)p(Y)$$

$$p(Y|X) = \frac{p(X|Y)p(Y)}{p(X)}$$

ベイズの定理

1.2節のイントロで考える問題

- 2つの箱(赤・青)に、青りんごとオレンジが入っている。
- 箱を1つランダムに選び、その後、果物を1つランダムに選ぶ。どの果物かを記録したら元の箱に戻す。



- 赤色の箱を選ぶ確率: $2/5$, 青色の箱を選ぶ確率: $3/5$
- 箱の中の果物は全てを等確率で選択する。

箱とフルーツの問題の定式化 ①

- 選んだ箱が「赤」、「青」である確率

$$p(B = r) = \frac{4}{10} = \frac{2}{5}, \quad p(B = b) = \frac{6}{10} = \frac{3}{5}$$

- 箱を選んだ後に、選んだフルーツが「青りんご」、「オレンジ」である確率

$$p(F = a|B = r) = \frac{1}{4}, \quad p(F = o|B = r) = \frac{3}{4}$$

$$p(F = a|B = b) = \frac{3}{4}, \quad p(F = o|B = b) = \frac{1}{4}$$

- 選んだフルーツが「青りんご」である確率

- 選んだ箱が赤の場合と青の場合を足し合わせる。

$$\begin{aligned} p(F = a) &= p(F = a|B = r)p(B = r) + p(F = a|B = b)p(B = b) \\ &= \frac{1}{4} \times \frac{2}{5} + \frac{3}{4} \times \frac{3}{5} = \frac{11}{20} \end{aligned}$$

箱とフルーツの問題の定式化 ②

- 「オレンジ」を選んだとき、それが「赤」色の箱から選ばれた確率
 - 「オレンジ」を選んだということを全体としたとき、それが「赤」、「青」のどちらであるかを考えることができる。

$$p(B = r|F = o) = \frac{p(F = o|B = r)p(B = r)}{p(F = o)} = \frac{3/4 \times 2/5}{9/20} = \frac{2}{3}$$


ベイズの定理

「ベイズの定理」を意識しなくても、全体(オレンジ)と部分(オレンジかつ赤)を意識すると、6/20を9/20で割ることは明らか。

- 選ばれたフルーツがわからないとき、どの箱が選ばれたかの確かさを表す確率を「(箱に関する)事前確率」という。
- 一方で、選ばれたフルーツがわかった後に、どの箱が選ばれたかの確かさを表す確率を「(箱に関する)事後確率」という。

事前確率

$$p(B = r) = \frac{2}{5}$$



$$p(B = r|F = o) = \frac{2}{3}$$

事後確率

確率変数と独立

- 確率変数 X, Y が**独立**

- 同時確率が個々の変数の確率の積に分解できる。

$$p(X, Y) = p(X)p(Y)$$

- 条件付き確率と**独立**

- 条件付き確率が条件付けている変数に依存しない。

$$p(Y|X) = p(Y)$$

※ 先ほどの箱とフルーツの例では $p(F = a) \neq p(F = a|B = r)$ となるため、確率変数 F, B は独立ではない。

1.2.1節の紹介

■ 1.2.1節 確率密度

確率密度関数

- 確率変数 x が連続で、その値が区間 (a, b) にある確率

$$p(x \in (a, b)) = \int_a^b \underline{p(x) dx}$$

確率密度関数

- 確率密度関数が満たす性質

① 確率密度関数は非負

② 全区間で積分すると1


$$p(x) \geq 0, \forall x \quad \int_{-\infty}^{\infty} p(x) dx = 1$$

- 累積密度関数 $P(z)$:
確率変数 x が z 以下となる確率

$$P(z) = \int_{-\infty}^z p(x) dx$$




$$\frac{d}{dx} P(x) = p(x)$$



確率密度関数の変数変換

※ x, y の確率密度関数を $p_x(x), p_y(y)$ とここでは表すことにする。

- x, y の間に $x = g(y)$ という関係があり、 x の確率密度関数 $p_x(x)$ がわかっているとき、 $p_y(y)$ がどのように表されるかを考える。
- x の世界の区間 $(x, x + \delta x)$ が、 y の世界の区間 $(y, y + \delta y)$ に対応するとき、 $p(x)\delta x \approx p(y)\delta y$ が成立する。


$$p_y(y) = p_x(x) \left| \frac{dx}{dy} \right| = p_x(g(y)) |g'(y)|$$

【cf. 2次元の場合】

- $(x, y) = (h_1(z, w), h_2(z, w))$ のときは、ヤコビアンを使って変数変換をする。

$$J = \begin{pmatrix} \frac{\partial h_1(z, w)}{\partial z} & \frac{\partial h_1(z, w)}{\partial w} \\ \frac{\partial h_2(z, w)}{\partial z} & \frac{\partial h_2(z, w)}{\partial w} \end{pmatrix} \quad \rightarrow \quad p_{z,w}(z, w) = p_{x,y}(x, y) \times |\det J(z, w)|$$

確率密度関数に関するその他のコメント

- 多変数の場合も1変数と同様の式が成立する。

$$p(\boldsymbol{x}) \geq 0, \forall \boldsymbol{x} \quad \int \underline{p(\boldsymbol{x})} \, d\boldsymbol{x} = 1$$

同時確率密度関数

- 周辺確率と条件付き確率の公式の連続版

$$p(x) = \int p(x, y) \, dy \quad p(x, y) = p(y|x)p(x) = p(x|y)p(y)$$

1.2.2節の紹介

■ 1.2.2節 期待値と分散

期待値

- 離散分布(確率分布: $p(x)$)の場合

$$\mathbb{E}[f(x)] = \sum_x p(x) f(x)$$

- 連続分布(確率分布: $p(x)$)の場合

$$\mathbb{E}[f(x)] = \int p(x) f(x) dx$$

- コンピュータなどで期待値の計算を行う場合

- 真の確率分布 $p(x)$ から N 個のデータ点が得られているだけで、確率分布自体はわからない。
- 期待値の計算は、得られたデータの平均値で近似する。

$$\mathbb{E}[f(x)] \approx \frac{1}{N} \sum_{n=1}^N f(x_n)$$

分散と共分散

- $f(x)$ の分散 (variance) の定義

$$\text{var}[f(x)] = \mathbb{E} \left[(f(x) - \mathbb{E}[f(x)])^2 \right] = \mathbb{E} [f(x)^2] - \mathbb{E}[f(x)]^2$$



$$\text{var}[x] = \mathbb{E} [x^2] - \mathbb{E}[x]^2$$

- 2つの確率変数 x, y の共分散 (covariance) の定義

$$\text{cov}[x, y] = \mathbb{E}_{x,y} [(x - \mathbb{E}[x]) (y - \mathbb{E}[y])] = \mathbb{E}_{x,y} [xy] - \mathbb{E}[x]\mathbb{E}[y]$$

- 2つの確率変数がベクトルの場合

$$\begin{aligned} \text{cov}[\mathbf{x}, \mathbf{y}] &= \mathbb{E}_{\mathbf{x}, \mathbf{y}} \left[(\mathbf{x} - \mathbb{E}[\mathbf{x}]) (\mathbf{y} - \mathbb{E}[\mathbf{y}])^\top \right] \\ &= \mathbb{E}_{\mathbf{x}, \mathbf{y}} [\mathbf{x} \mathbf{y}^\top] - \mathbb{E}[\mathbf{x}] \mathbb{E}[\mathbf{y}^\top] \end{aligned}$$


1.2.4節の紹介

■ 1.2.4節 ガウス分布

ガウス分布（正規分布）：1変数

- 平均 μ , 分散 σ^2 の1変数の正規分布(ガウス分布)

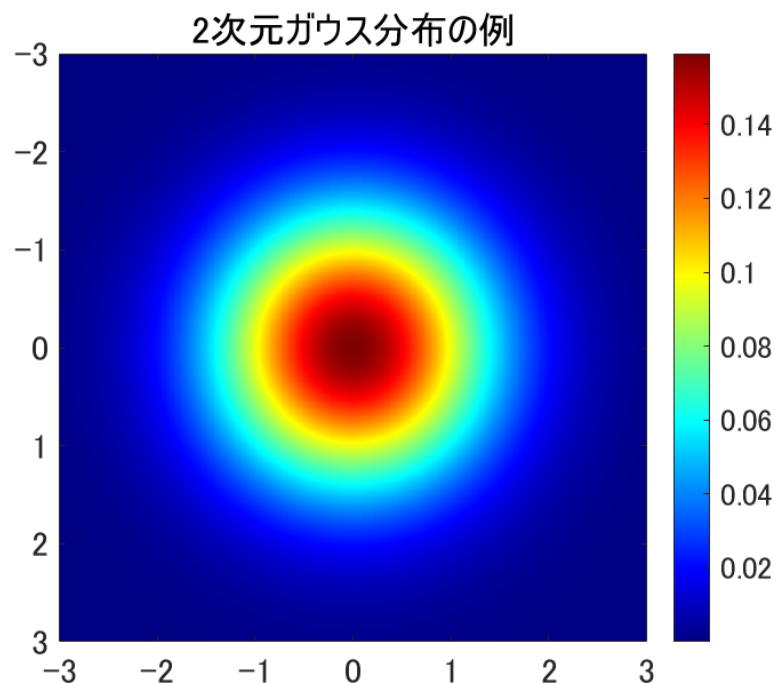
$$\mathcal{N}(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$



ガウス分布（正規分布）：多変数

- D次元変数 $\mathbf{x} = (x_1, \dots, x_D)^\top$ の場合。
- 平均ベクトル $\boldsymbol{\mu}$, 分散共分散行列 Σ の
多変数正規分布(ガウス分布)の確率密度関数

$$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \Sigma) = \frac{1}{\sqrt{(2\pi)^D (\det \Sigma)}} \exp \left(-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right)$$



- 平均ベクトル：0
- 分散共分散行列：単位ベクトル
の場合のガウス分布の値（左図）

$$f(\mathbf{x}) = \frac{1}{2\pi} \exp \left(-\frac{1}{2} \mathbf{x}^\top \mathbf{x} \right)$$

独立同一分布

- 1変数 x の観測値として N 個の値が得られている。
この値がある分布から独立に生成されたと仮定する。
⇒ N 個のデータは「独立同一分布に従う」という。

- ある1変数ガウス分布から N 個の観測値が独立に得られているとき、この分布の平均、分散を推定することを考える。



- N 個の観測データをまとめたベクトル: $\mathbf{x} = (x_1, \dots, x_N)^\top$
- N 個の観測データの同時確率

$$p(\mathbf{x} | \mu, \sigma^2) = \prod_{n=1}^N \mathcal{N}(x_n | \mu, \sigma^2) = \prod_{n=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_n - \mu)^2}{2\sigma^2}\right)$$

最尤推定

- パラメータを決めるために**最尤推定**を使用する。
 - 最尤推定: 観測されたデータ集合の(同時)確率を最大にするパラメータを選択する。
 - そのようなパラメータが「最も尤もらしい」と考える。
- 同時確率の式をパラメータ μ, σ^2 の関数とみる。
⇒ パラメータの関数としてみたものを「**尤度関数**」という。

$$f(\mu, \sigma^2) = \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^N \exp \left(-\frac{1}{2\sigma^2} \sum_{n=1}^N (x_n - \mu)^2 \right)$$



- 尤度関数の対数(**対数尤度関数**)を利用すると楽になる。

$$\ln f(\mu, \sigma^2) = -\frac{N}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{n=1}^N (x_n - \mu)^2 + \text{const.}$$

最尤推定の解の計算

$$\ln f(\mu, \sigma^2) = -\frac{N}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{n=1}^N (x_n - \mu)^2 + \text{const.}$$

- ① μ で偏微分して0になる点を計算。

$$\frac{\partial \ln f(\mu, \sigma^2)}{\partial \mu} = \frac{1}{\sigma^2} \sum_{n=1}^N (x_n - \mu) = 0 \quad \Rightarrow \quad \mu_{\text{ML}} = \frac{1}{N} \sum_{n=1}^N x_n$$

N個の観測データの平均値

- ② 同様に σ^2 で偏微分して0になる点を計算。

$$\frac{\partial \ln f(\mu, \sigma^2)}{\partial \sigma^2} = -\frac{N}{2} \frac{1}{\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{n=1}^N (x_n - \mu_{\text{ML}})^2 = 0$$

$$\Rightarrow \sigma_{\text{ML}}^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \mu_{\text{ML}})^2$$

N個の観測データの分散

最尤推定量の期待値 (1/3)

- パラメータの最尤推定値は観測データから計算されるので、観測データによるバラツキを持つ確率変数である。
⇒ 「最尤推定量の期待値」について考える。

① 平均 (μ) の最尤推定値の期待値

$$\mu_{\text{ML}} = \frac{1}{N} \sum_{n=1}^N x_n$$



$$\mathbb{E}[\mu_{\text{ML}}] = \frac{1}{N} \sum_{n=1}^N \mathbb{E}[x_n] = \frac{1}{N} \sum_{n=1}^N \mu = \mu$$

ガウス分布の平均: μ

最尤推定値の期待値が真の値と一致

- 推定量の期待値と真値が一致する推定量を「不偏推定量」という。
⇒ 推定値が真値の周りに分布している。
- 不偏推定量は推定量としては望ましいものの1つといえる。

最尤推定量の期待値 (2/3)

② 分散(σ^2)の最尤推定値の期待値

$$\sigma_{\text{ML}}^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \mu_{\text{ML}})^2 \quad \rightarrow \quad \mathbb{E}[\sigma_{\text{ML}}^2] = \frac{1}{N} \mathbb{E} \left[\sum_{n=1}^N (x_n - \mu_{\text{ML}})^2 \right]$$

• Σ 中の計算方法

$$\begin{aligned} (x_n - \mu_{\text{ML}})^2 &= \{(x_n - \mu) - (\mu_{\text{ML}} - \mu)\}^2 \\ &= (x_n - \mu)^2 - 2(x_n - \mu)(\mu_{\text{ML}} - \mu) + (\mu_{\text{ML}} - \mu)^2 \end{aligned}$$

$$\therefore \sum_{n=1}^N (x_n - \mu_{\text{ML}})^2 = \sum_{n=1}^N (x_n - \mu)^2 - N(\mu_{\text{ML}} - \mu)^2$$

n について和をとって整理する

$$\therefore \mathbb{E} \left[\sum_{n=1}^N (x_n - \mu_{\text{ML}})^2 \right] = N\sigma^2 - N\mathbb{E}[(\mu_{\text{ML}} - \mu)^2]$$

期待値計算をして整理する

• 以上より $\mathbb{E}[\sigma_{\text{ML}}^2] < \sigma^2$ が成立。

⇒ 分散の最尤推定量は不偏推定量ではない。

最尤推定量の期待値 (3/3)

- 分散の最尤推定量について、標本平均の分散に関する公式を利用。
⇒分散の最尤推定量の期待値が厳密に得られる。

$$\mathbb{E}[\sigma_{\text{ML}}^2] = \frac{N-1}{N} \sigma^2$$



分散の最尤推定量の期待値は
真値を過小評価している

- 上記の式から、以下の式で定義される「**不偏標本分散**」の期待値は、分散パラメータの真値と一致する。

$$\tilde{\sigma}^2 := \frac{N}{N-1} \sigma_{\text{ML}}^2 = \frac{1}{N-1} \sum_{n=1}^N (x_n - \mu_{\text{ML}})^2$$

1.2.5節の紹介

■ 1.2.5節 曲線フィッティング再訪

1.2.6節の紹介

■ 1.2.6節 ベイズ曲線フィッティング

